算法测试结果

使用新下载的数据集丰富恶意指令，使用有监督学习算法knn、svm、决策树在新的数据集上训练，得到的算法准确率有了明显的提升。

数据集说明

恶意指令比较稀少，所以从网络上获取其他的部分linux指令，未与已有正常指令重复的，当做恶意指令，参与模型训练。指令来自

https://www.runoob.com/linux/linux-command-manual.html

https://man.linuxde.net

有监督学习

knn与radius knn

knn

模型准确率

	precision	recall
正常样本	1.00	1.00
恶意样本	0.99	0.99

Nradiusknn

模型准确率

	precision	recall
正常样本	0.74	1.0
恶意样本	0	0

学习曲线

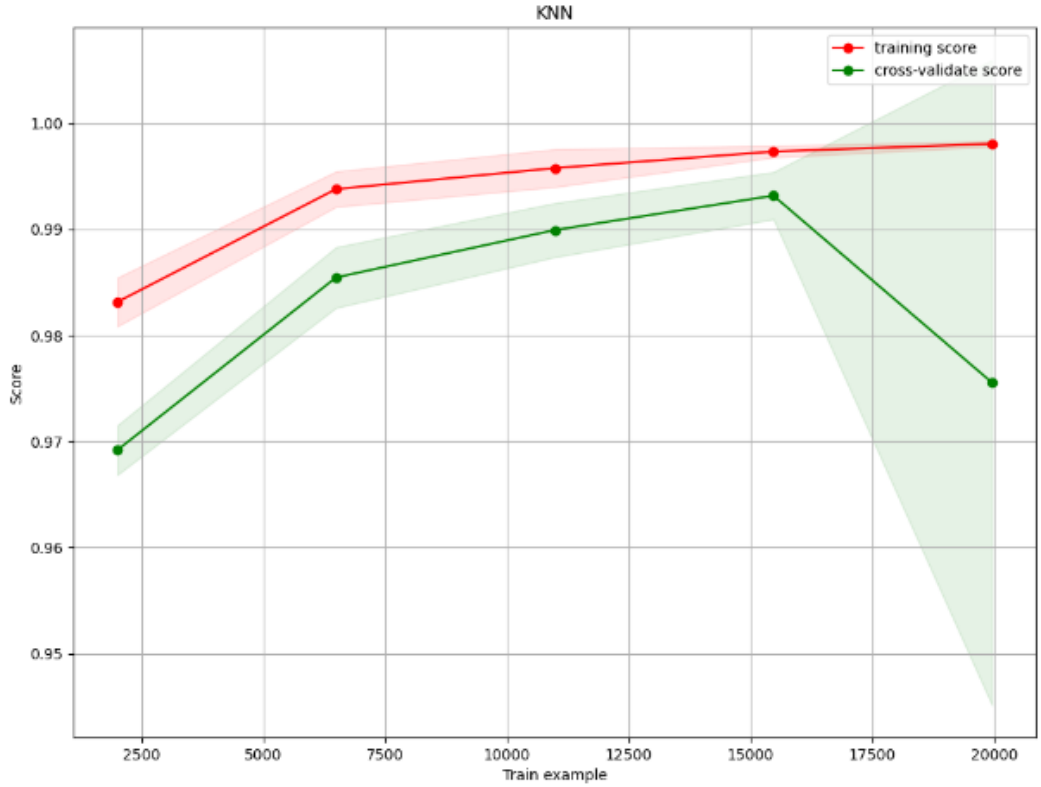

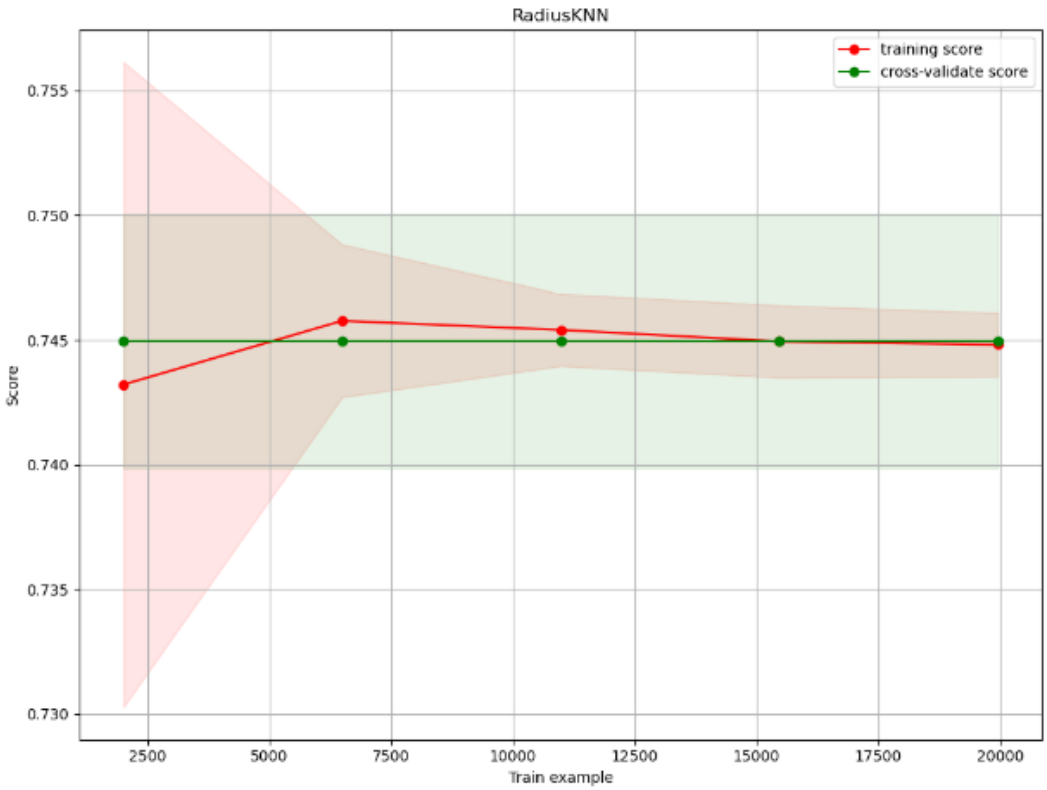

knn与RadiusKnn的学习曲线如上图，radiusknn的表现很差，不做讨论。从knn的学习曲线可以看出，随着训练样本增加，模型在测试集上的准确率下降，且方差变大，具有过拟合的特征， 在样本达到15000时，准确率达到最高的0.99

kfold交叉验证

```
[0.94808579 0.89316496 0.9965925  0.94066947 0.99579074]
```

经过多次测试，knn算法准确性不稳定，准确率在89%与99%之间波动

SVM

准确性如下

	precision	recall
normal	1.00	1.00
abnormal	0.99	1.00

学习曲线

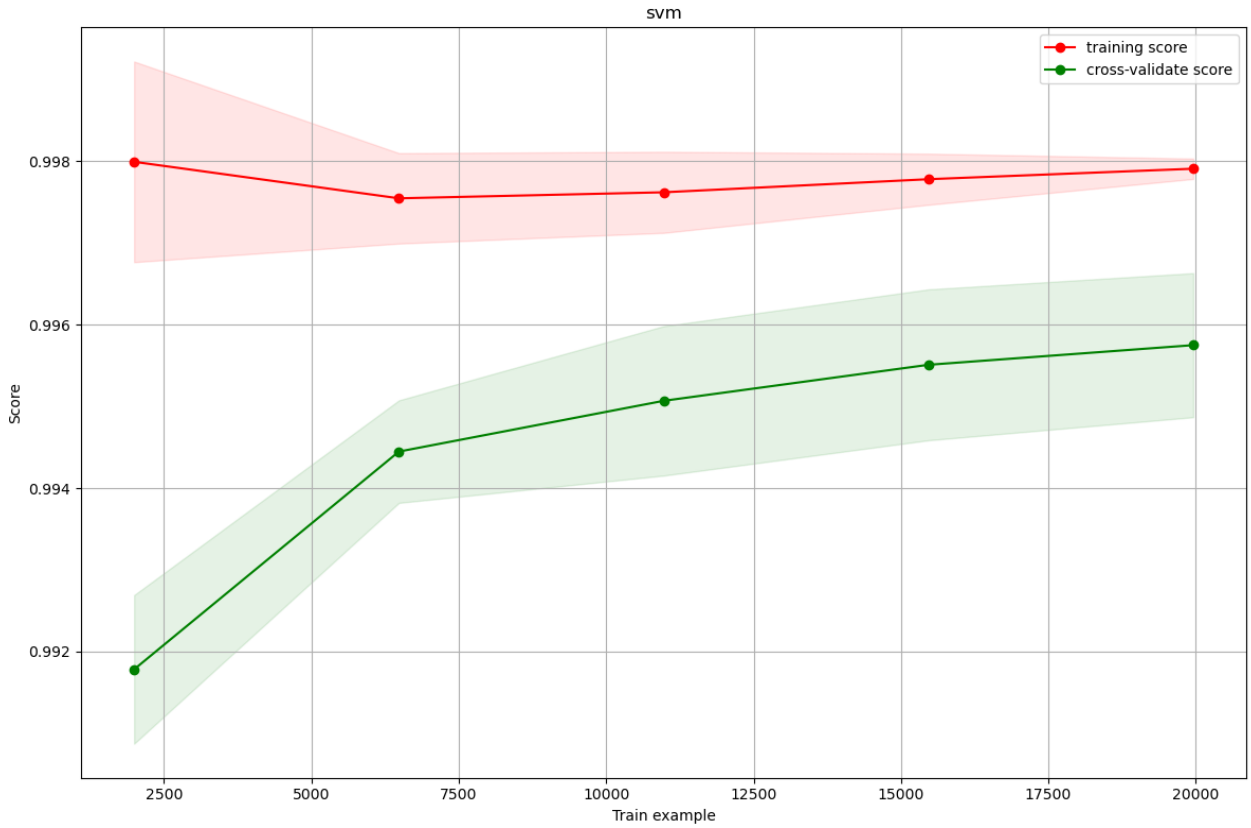

svm的学习曲线较为正常，模型准确率在训练集和测试集的准确率都比较高，而且上升趋势仍未停止，当前准确率99%，随着数据集增加，准确率有可能进一步提高，并且误差在1%之内，表现良好

kfold 交叉验证准确率

```
[0.99438765 0.99538986 0.99819603 0.99699339 0.99458809]
```

DT

准确性如下

	precision	recall
normal	1.00	0.98
abnormal	0.95	1.00

模型学习曲线如下

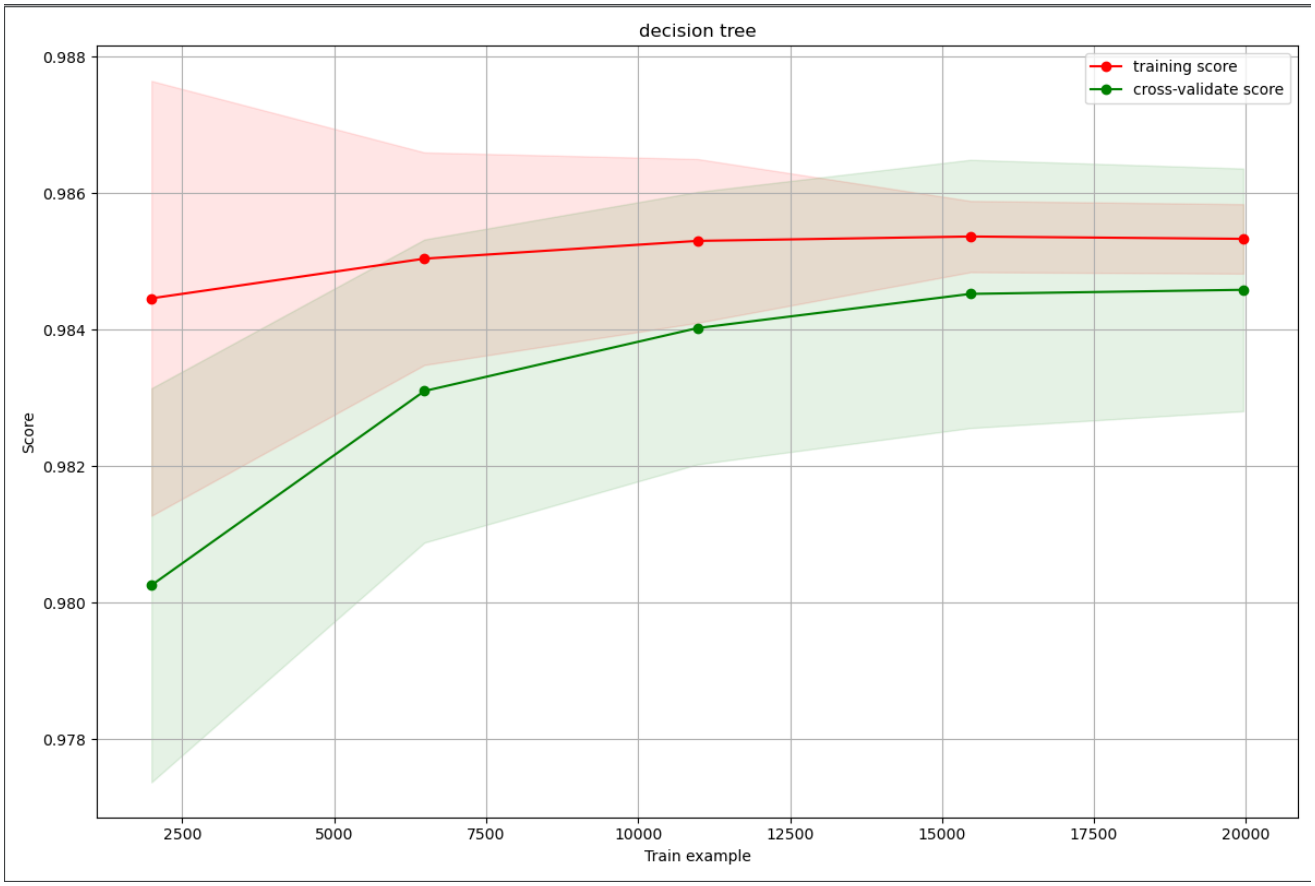

从学习曲线来看，该模型表现与svm相当，随着数据集增加，准确率都有逐步提高，当数据到达17500时，准确率变化已趋于平缓，在训练集与测试集的准确率都达到98%，未出现过拟合的现象，并且误差范围在1%之内。

kfold 5折交叉验证准确率

```
[0.98376428 0.98256164 0.98456605 0.98276208 0.98737222]
```

Bayes

准确率

	precision	recall
normal	1.00	1.00
abnormal	1.00	0.99

学习曲线如下

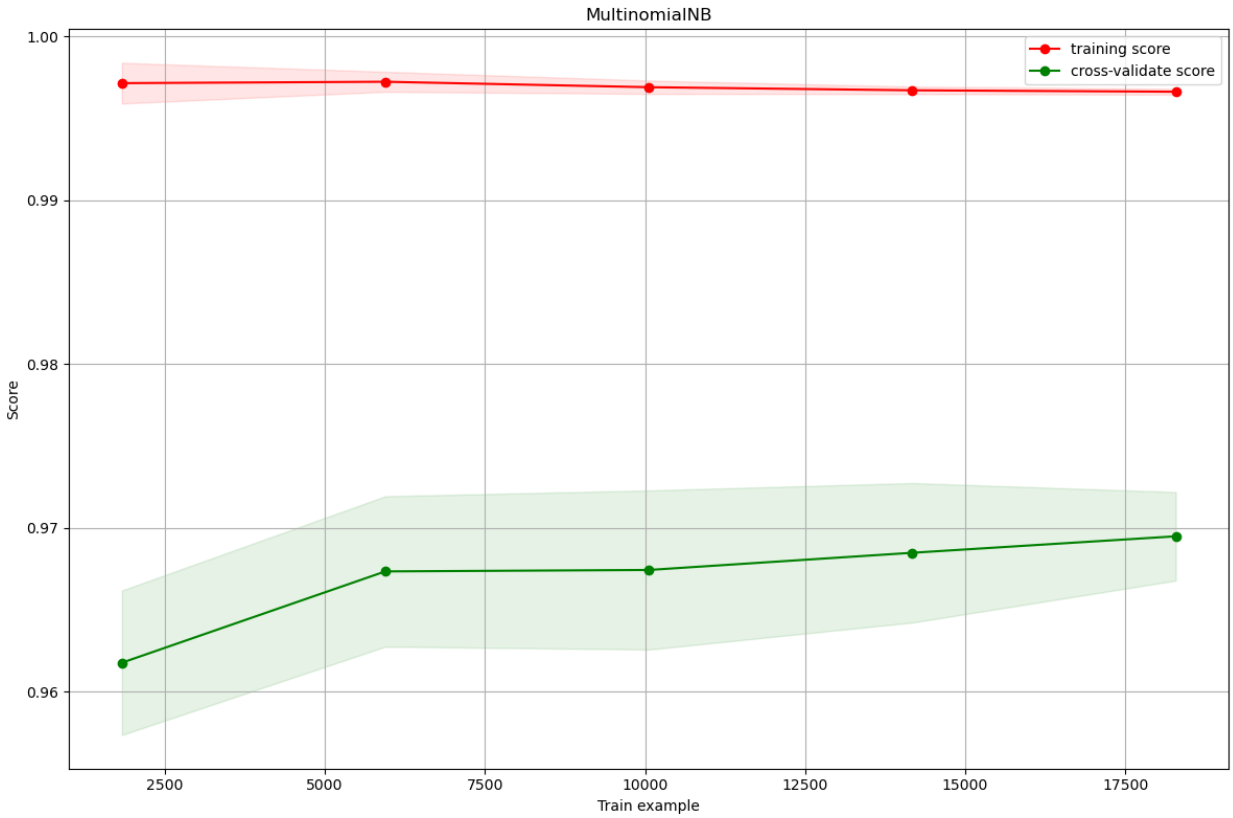

模型在测试集上的准确率不如训练集上的高，但测试集准确率有上升趋势，模型未表现出轻微过拟合特征，准确率在97%左右，误差范围在1%以内

kfold交叉验证结果

```
[0.96587927 0.97287839 0.96959755 0.97047244 0.96784074]
```

LDA

LDA算法在分类中的应用原理是将数据点映射到某条直线，使正常样本，异常样本分别聚集在不同的区域，以此达到数据分类的目的，使用LDA算法时，由于命令向量化以后得到的稀疏矩阵不能直接放到该算法中进行训练，需要先转换为一般矩阵，但是转换后结果过于庞大导致内存溢出，因此先进行降维操作，使用PCA算法降低命令向量的维数，选择的目标维数与数据还原率的变化如下

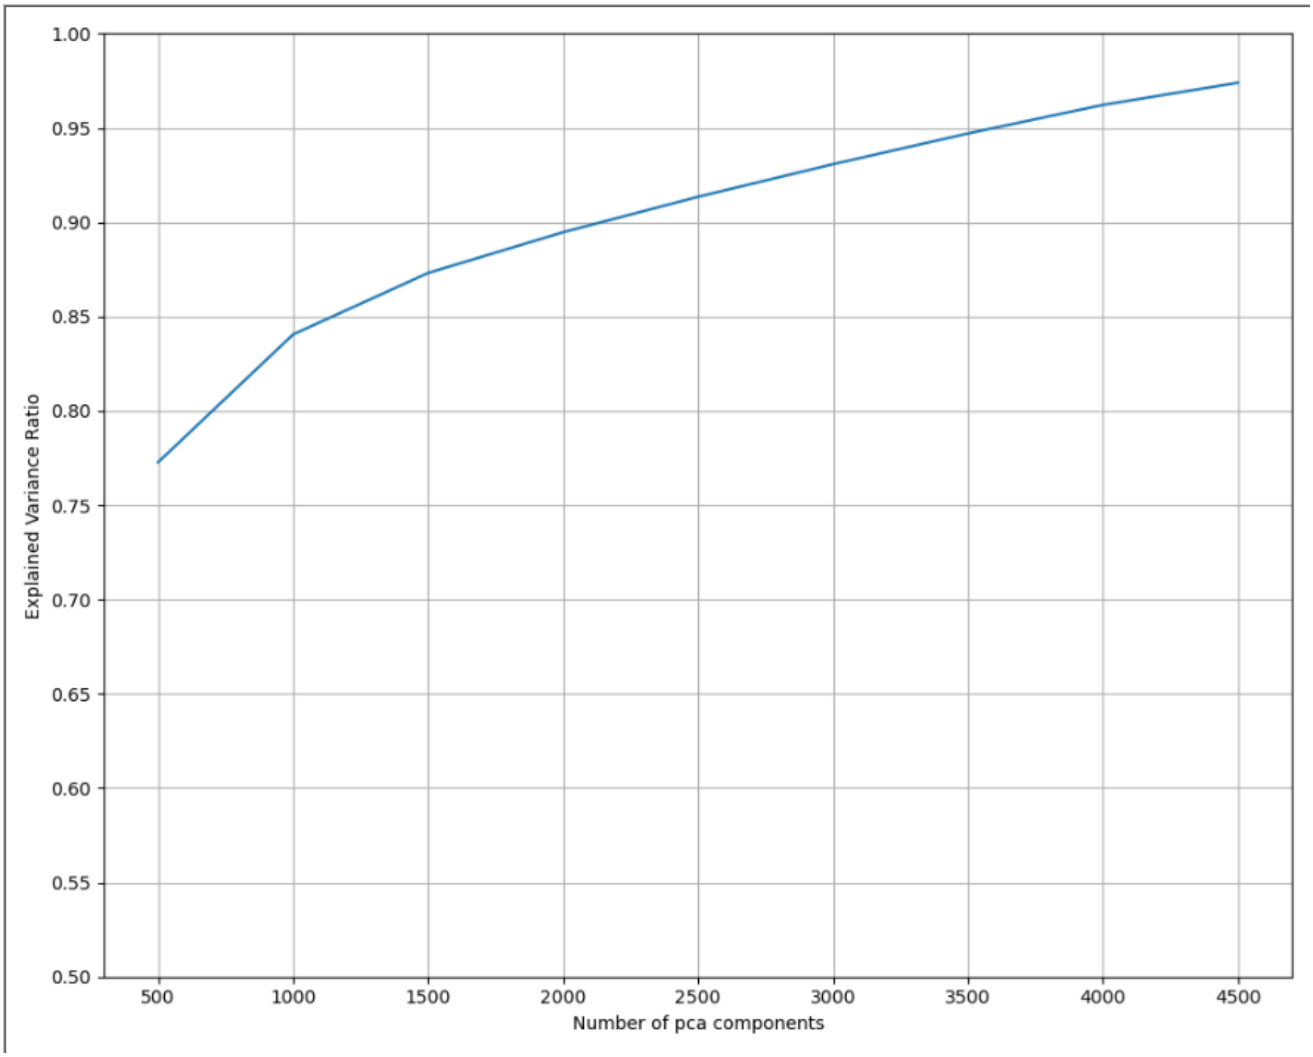

我们选择目标维数4000（数据还原率大于95%）。测试结果如下

	precision	recall
normal	0.99	0.94
abnormal	0.79	0.97

无监督学习

kmeans

先使用tfidf将所有正常指令向量化，取出部分指令与恶意数据一起参与模型测试。

我们选择一个距离阈值，当某条命令向量与聚类中心的距离过远，我们就把这条指令当做恶意指令。测试时，我们划分一个阈值范围，在此范围内求模型的准确率与召回率，以此来分析模型在此问题上的表现。

准确率与召回率随距离阈值变化

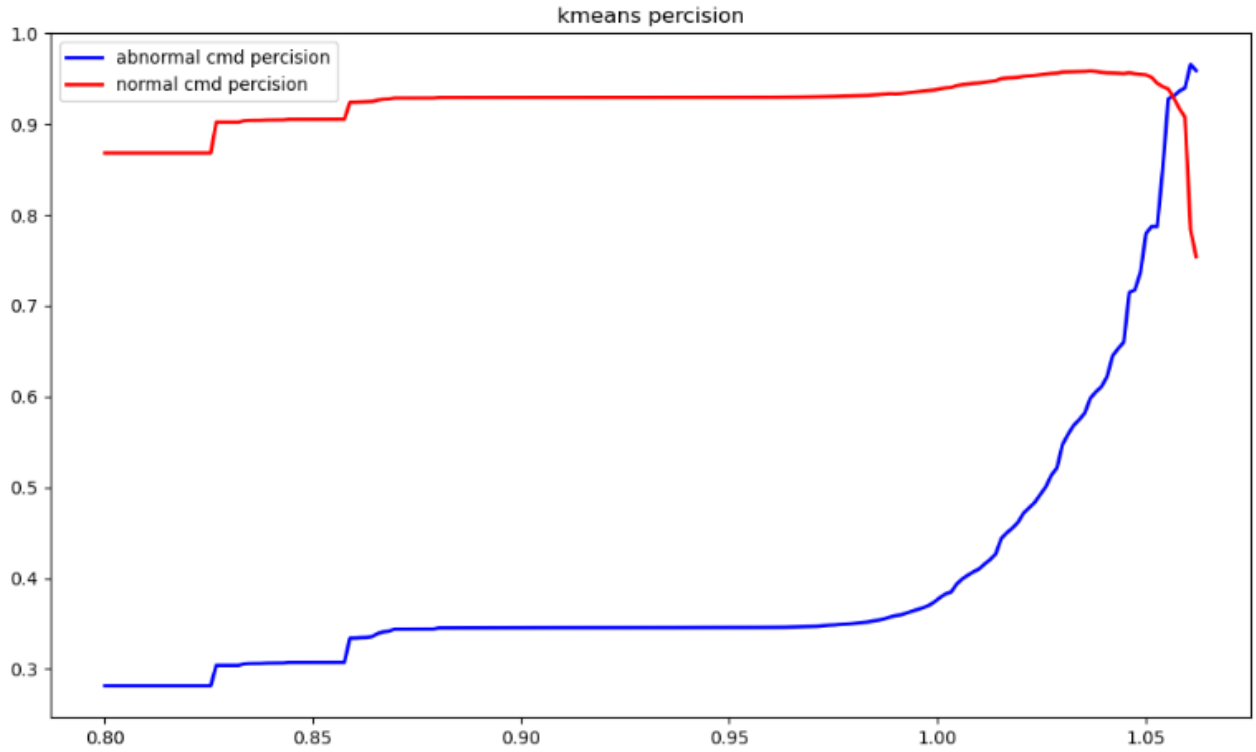

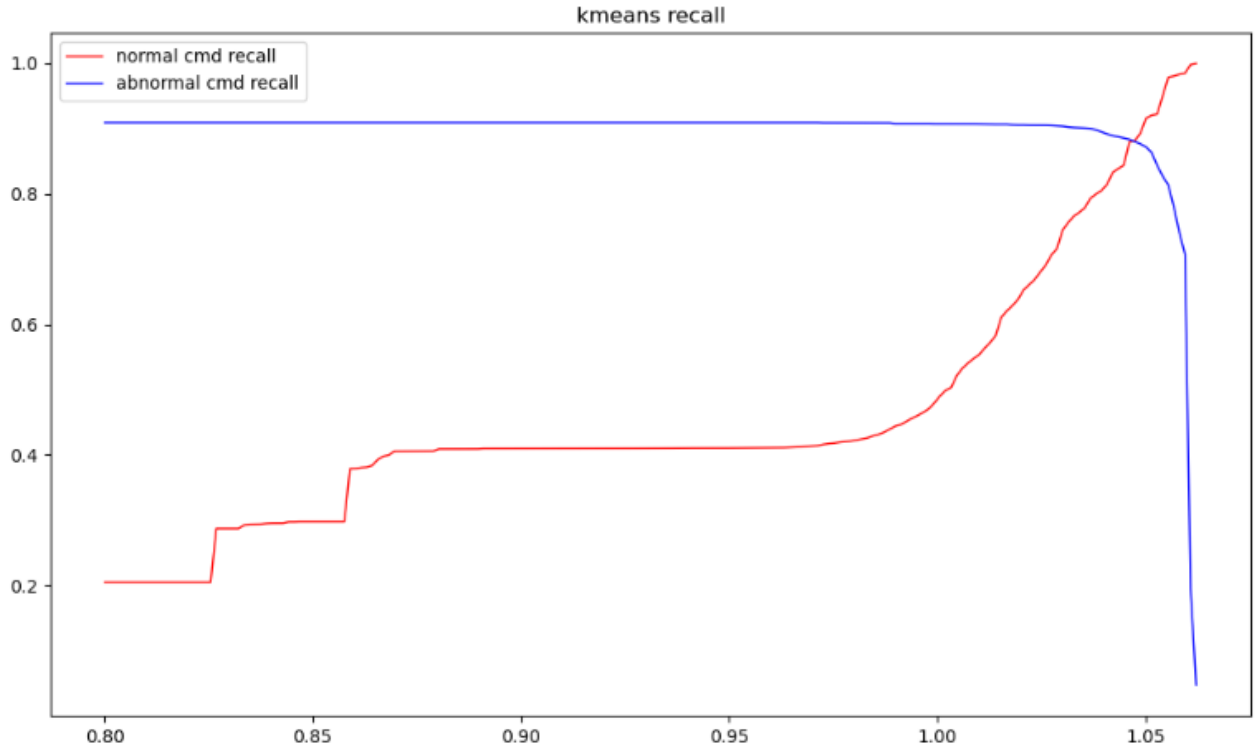

在阈值取1.05左右时准确率与召回率达到最优，约为0.9左右，但是曲线在大于1.05的时候下降的非常陡峭，表示微小的阈值变化会引起较大的误差。此种应用模型的方式不太适合用来处理这个问题。

n-gram based knn

通过n-gram计算命令之间的距离，通过指定距离阈值，判断命令是否恶意。

我们在正常数据集中随机无放回地取出1000条指令，计算这1000条正常指令与原数据集n-gram距离的最小值

并且计算恶意指令与原数据集n-gram距离的最小值

得到的统计图表如下

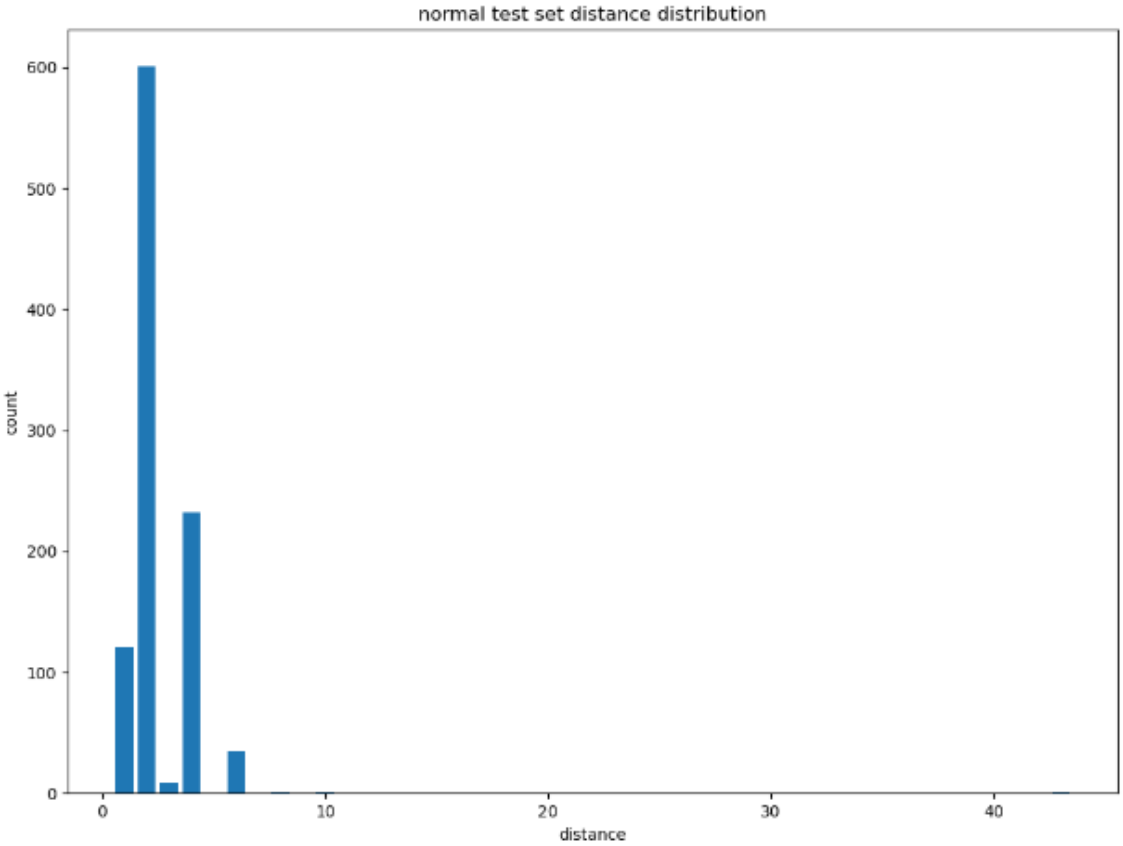

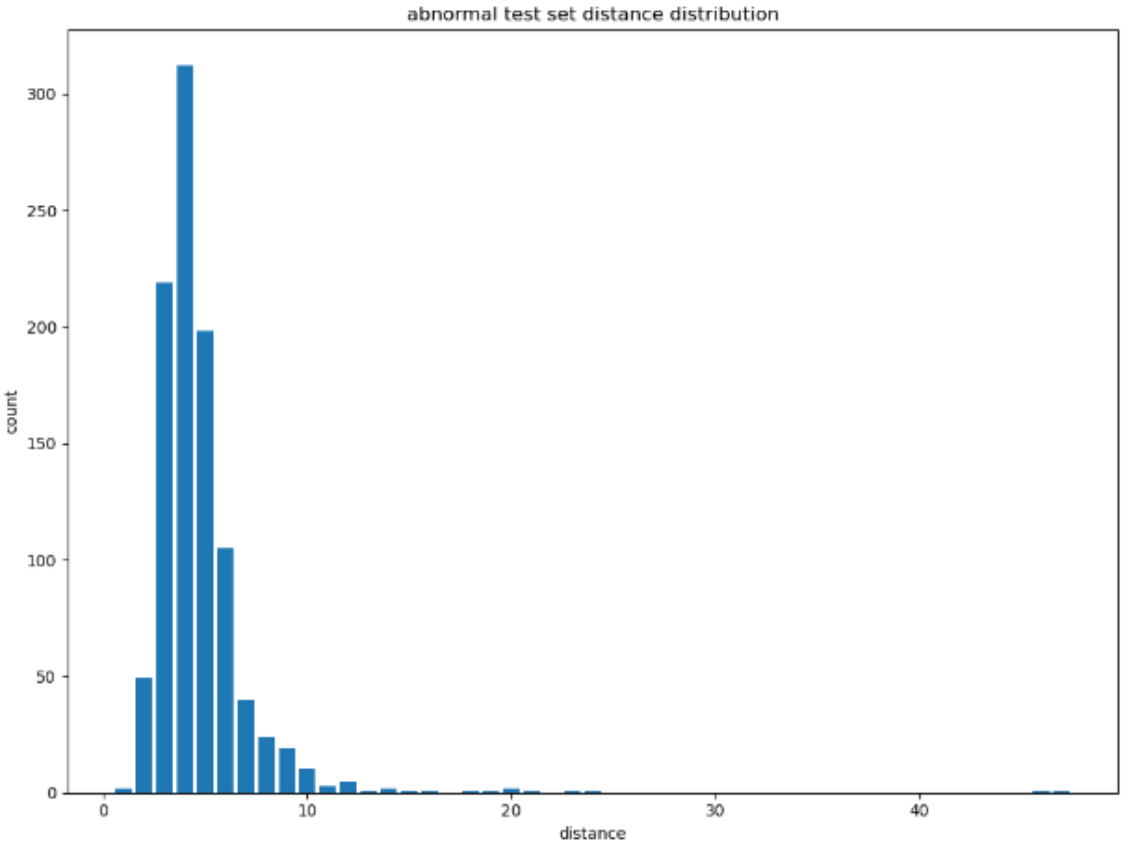

使用n为1的绝对n-gram距离衡量命令差异不是一个好的选择。假设某条命令用空格分隔后有100个关键字，此时在我们的正常数据集中，有一条指令和它只有一个参数不同，它们的1-gram距离我们可以计算得2，我们倾向于认为该指令是一个正常指令，因为它与训练数据集中的一条指令相似度达到了99%。假设还有一条指令ifconfig，训练集中有长度为1的指令，他们的n-gram距离也是2，但是这条指令显然是恶意的，因为它之前并没有出现过。产生这种问题的原因是因为绝对的n-gram距离在衡量指令差异性上存在一些不足，我们如果将指令长度考虑进来，对计算后的n-gram距离做归一化处理，那么计算后的距离转换为0-1之间的小数，还是上面的两个例子，ifconfig与训练集的归一化n-gram距离将变为1，而长为100的指令，由于有99个关键字都相同，归一化距离变为0.01，一定程度上增加了模型准确性。

在此数据集上，n-gram距离的分布如下

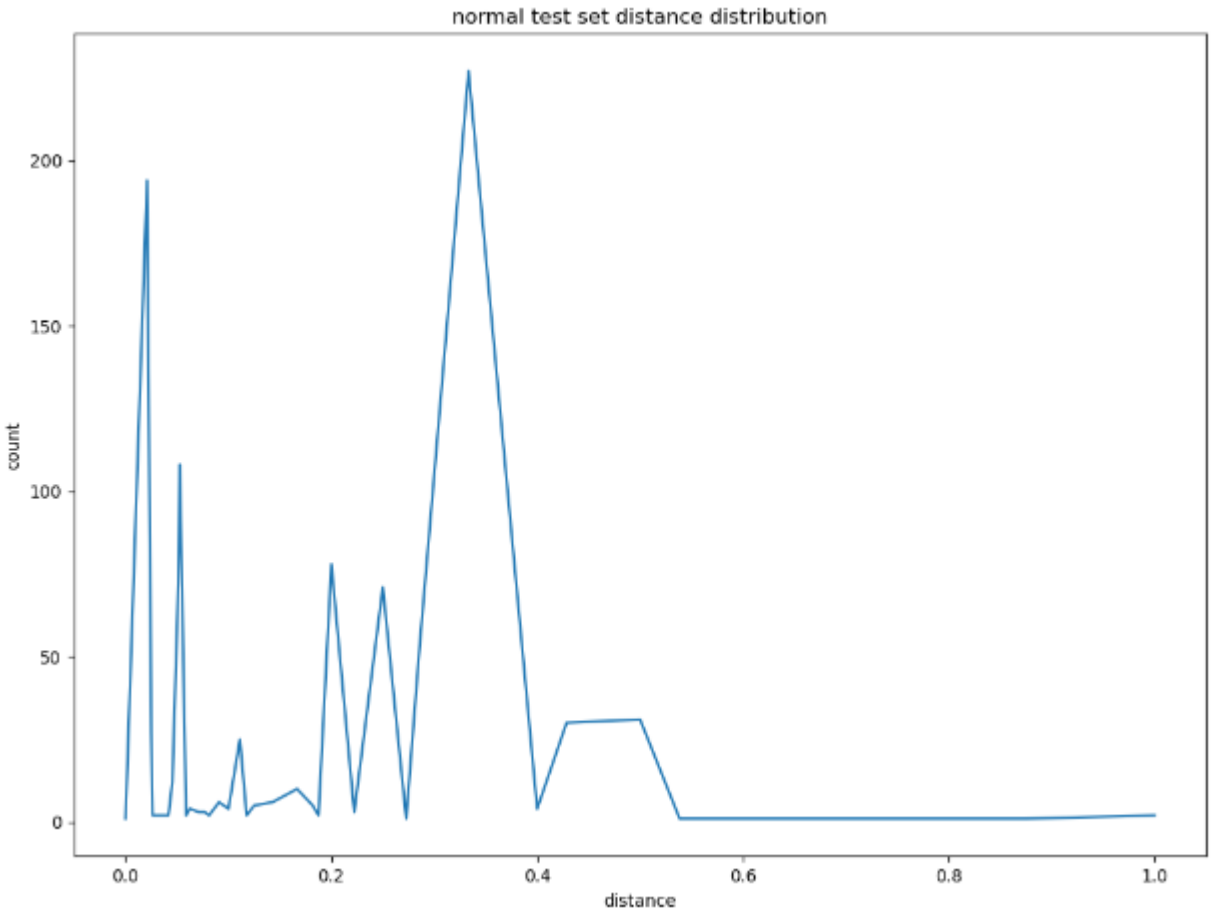

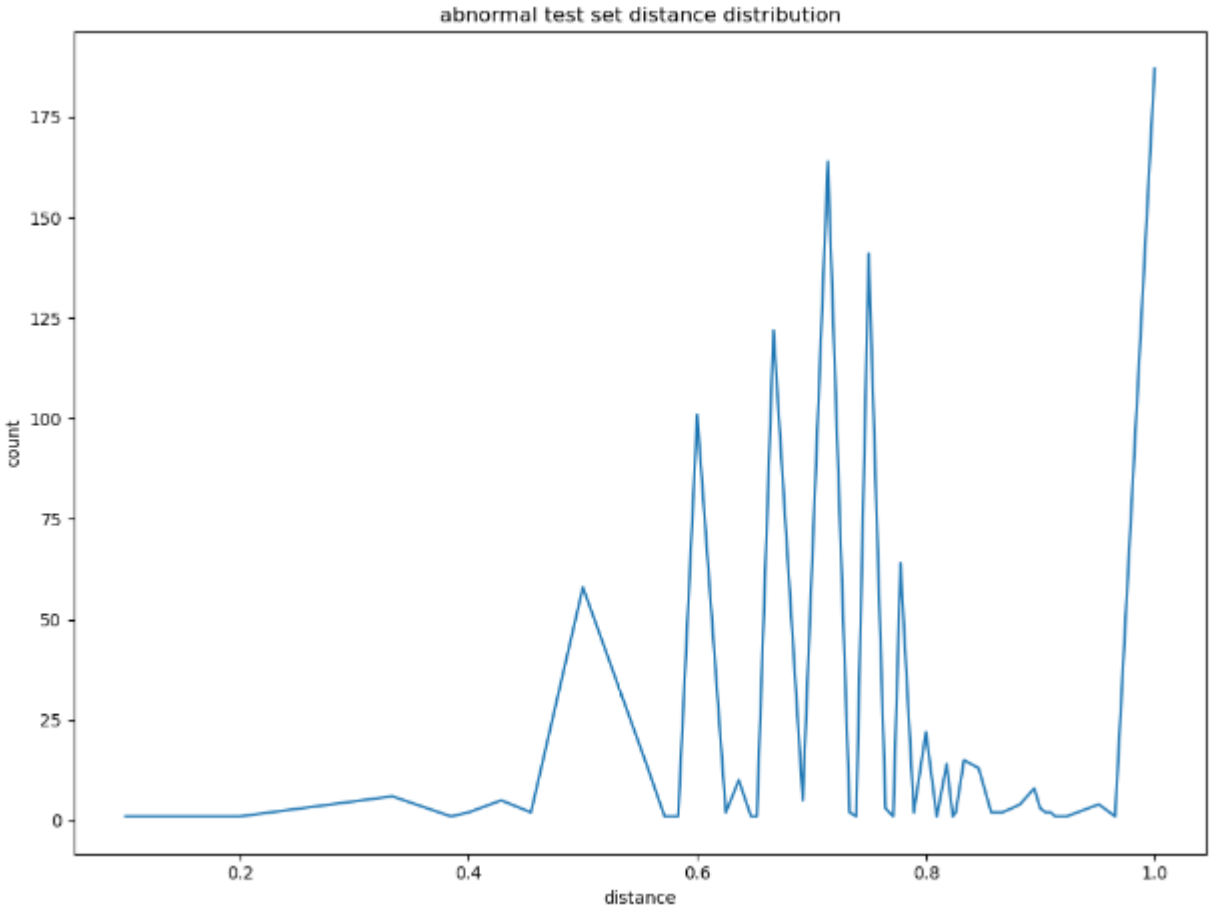

我们使用归一化n-gram距离的knn算法，选择0.2到0.7之间均匀选择20个数作为距离界限，得到的准确性分布如下

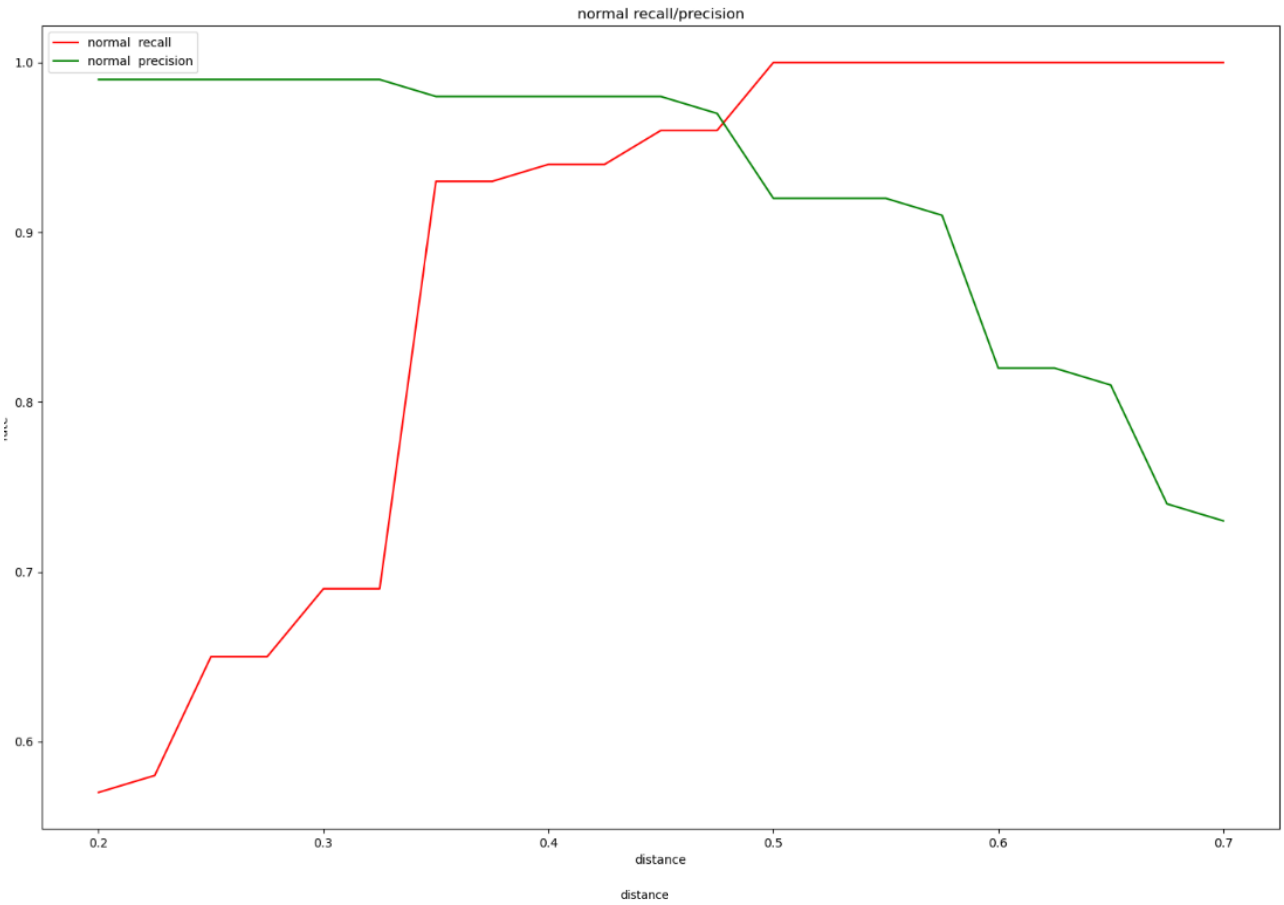

distance

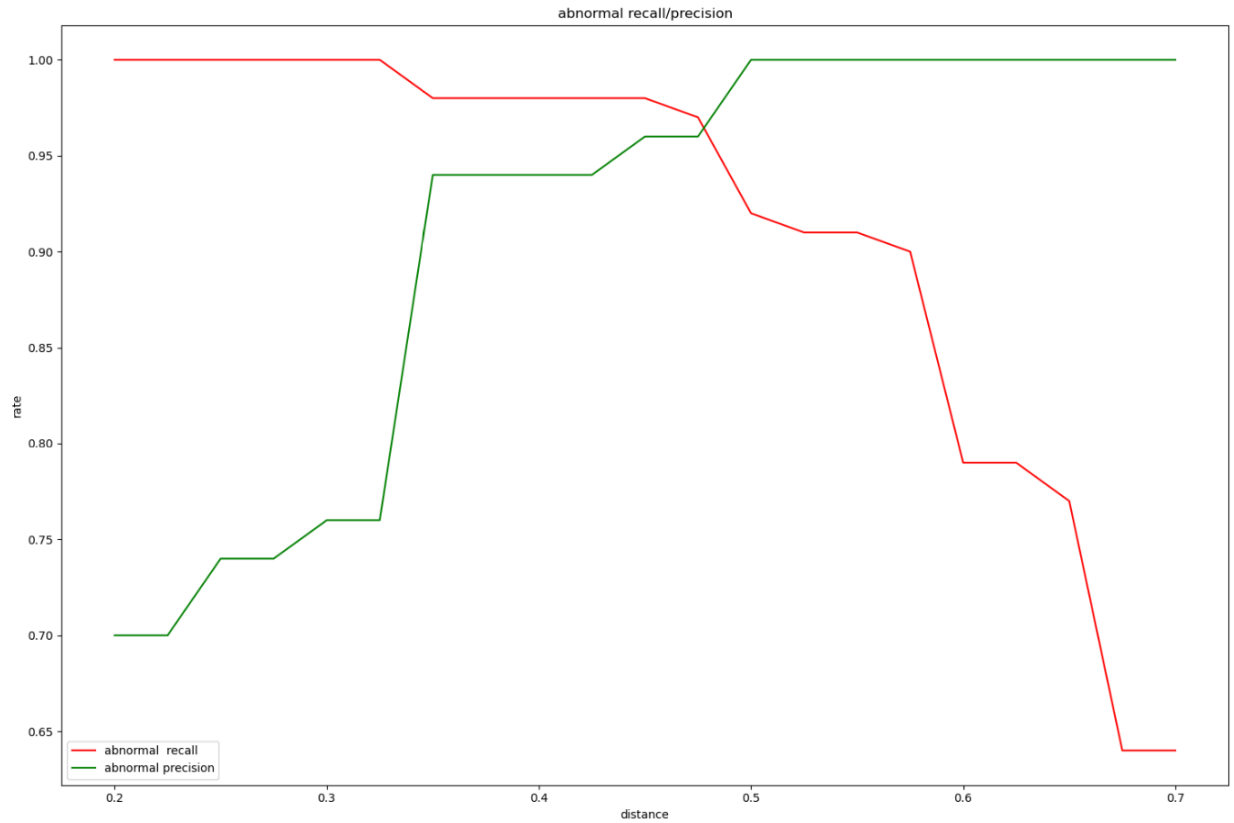

在距离界限取0.45时，模型取得理想的准确率与召回率

	precision	recall
normal	0.98	0.96
abnormal	0.96	0.98

异常检测

使用pca算法降维后（3500）

OneClassSVM

	accuracy	recall
normal	0.99	0.96
abnormal	0.86	0.95

Iforest

	precision	recall
normal	0.85	0.84
abnormal	0.33	0.34